

MINI RAG / HỒ SƠ KỸ THUẬT

Luồng dữ liệu và truy xuất tài liệu

Các mốc triển khai, bằng chứng kiểm thử và kết quả đánh giá

Ngày cập nhật: 30/09/2026

Kho mã nguồn trên GitHub: github.com/SharkTien/miniRAG

Mục lục

3. Các mốc thực hiện	3
Mốc 1 — Luồng dữ liệu	3
Các mô hình và vai trò trong luồng	3
Sơ đồ kiến trúc triển khai	4
Mốc 2 — API hỏi đáp	4
Mốc 3 — Đóng gói và kiểm tra tự động	4
Mốc 4 — Tài liệu và trình diễn	4
4. Bằng chứng trực quan từ hệ thống	4
5. Nghiên cứu và xử lý dữ liệu	6
5.1 Hồ sơ dữ liệu	6
5.2 Thiết kế phép đo	7
5.3 So sánh phương án	7
5.4 Quyết định kỹ thuật từ dữ liệu	7
6. Kiểm thử đơn vị và kiểm thử API	7
6.1 Kiểm thử thành phần lỗi	7
6.2 Kiểm thử hợp đồng API	7
6.3 Kiểm thử xếp hạng bằng chứng	8
6.4 Kiểm thử nhận dạng ký tự và định tuyến	8
6.5 Kiểm thử kết nối mô hình NVIDIA	8
6.6 Kiểm chứng truy xuất	8
7. Cấu hình và nguồn sự thật	8
8. Đánh giá từng trường hợp kiểm tra truy xuất	9
1. Hoàn tiền bằng thẻ NAPAS	9
2. Shop giao sai hàng và phí trả hàng	9
3. Đổi riêng áo lỗi trong một bộ	9
4. Phụ kiện Adore	9
5. Bảo hành biến tần GD100-PV	9
6. Inverter gửi tới Nguyễn Văn Quá	10
7. Hotline Kamereo	10
8. Rau củ dập úng sau 14 giờ	10
9. Cách tạo source trong câu trả lời	10
10. Hạn chế và kế hoạch tiếp theo	11


3. Các mốc thực hiện

Mốc 1 — Luồng dữ liệu

Đã hoàn thành tải tài liệu, kiểm tra định dạng, lưu kho đối tượng, trích xuất PDF/TXT/DOCX và định dạng mở rộng, nhận dạng ký tự NVIDIA cho bản quét và ảnh, làm sạch, chuẩn hóa ngữ nghĩa có giới hạn thời gian, chia đoạn, tạo vector theo lô, lưu pgvector và xử lý nền.

MINI RAG / PIPELINE ATLAS

Kiến trúc luồng dữ liệu và truy xuất



Sơ đồ trên là luồng xử lý dữ liệu cuối cùng: tài liệu được trích xuất trước, làm sạch và chia đoạn theo cấu trúc, sau đó mới tạo vector và lưu cùng metadata. Khi hỏi, hệ thống dùng đồng thời điểm từ khóa và điểm ngữ nghĩa, lọc theo tài liệu, xếp hạng bằng chứng rồi mới gửi ngữ cảnh phù hợp cho mô hình trả lời.


Các mô hình và vai trò trong luồng

Thành phần	Mô hình/công nghệ	Vai trò
Nhận dạng ký tự	NVIDIA NeMo Retriever OCR v2	Đọc chữ trong PDF quét, ảnh và vùng bảng khi tài liệu không có lớp chữ.
Tạo vector	NVIDIA NeMo Retriever Embed 1B	Biến câu hỏi và từng đoạn thành vector cùng không gian để tìm kiếm ngữ nghĩa.
Chuẩn hóa ngữ nghĩa	Mô hình ngôn ngữ qua NVIDIA NIM	Chuẩn hóa tiêu đề, quan hệ bảng và tín hiệu truy vấn khi cần; có giới hạn thời gian và thử lại.
Sinh câu trả lời	Mô hình ngôn ngữ qua NVIDIA NIM	Tổng hợp câu trả lời chỉ từ các bằng chứng đã được chọn và trả kèm nguồn.
Lưu trữ và tìm kiếm	PostgreSQL + pgvector + toàn văn	Lưu vector/metadata và kết hợp tìm kiếm ngữ nghĩa với từ khóa.

Sơ đồ kiến trúc triển khai

MINI RAG / ARCHITECTURE ATLAS

Các lớp triển khai và mô hình xử lý



ĐIỂM CHÍNH API nhận yêu cầu; worker xử lý nặng; kho lưu trạng thái và bằng chứng; mô hình chỉ nhận ngữ cảnh đã lọc.

Kiến trúc tách rõ bốn lớp: giao diện gửi yêu cầu, API điều phối, lưu trữ/tiến trình nền và lớp mô hình. Tài liệu chỉ ghi nhận nhanh trạng thái queued; worker mới thực hiện trích xuất, OCR, chuẩn hóa, chia đoạn và tạo vector. Truy vấn đi qua planner, hybrid retrieval và EvidenceService trước khi mô hình ngôn ngữ nhận context.

- Hồ sơ nghiên cứu dữ liệu được bàn giao kèm báo cáo và dùng làm căn cứ cho các quyết định kỹ thuật.
- 877 câu hỏi được phân loại theo bảng, biểu mẫu, hình, chú thích và văn bản.
- Các phương án OCR, mở rộng tập ứng viên, tìm kiếm kết hợp, xử lý bảng, hình và chú thích được chạy trên cùng bộ câu hỏi.

Mốc 2 — API hỏi đáp

API hỏi đáp, lập kế hoạch truy vấn, tìm kiếm toàn văn kết hợp vector, mở rộng tập ứng viên, lọc danh tính tài liệu, xếp hạng bằng chứng, lời nhắc bám nguồn, trích dẫn nguồn và trả kết quả từng phần đã có trong mã nguồn.

Mốc 3 — Đóng gói và kiểm tra tự động


Dockerfile, Docker Compose cho API, tiến trình nền, PostgreSQL + pgvector, MinIO và giao diện, tệp cấu hình mẫu và quy trình GitHub Actions đã có. Cổng chất lượng đạt 98,8/100; ảnh chụp quy trình nằm ở phần bằng chứng.

Mốc 4 — Tài liệu và trình diễn


README, tài liệu kiến trúc, ví dụ API, kịch bản trình diễn, truy vết yêu cầu, bảng kiểm tra truy xuất và báo cáo PDF này được bàn giao.

4. Bằng chứng trực quan từ hệ thống


Các ảnh dưới đây được lấy từ quá trình chạy thật của hệ thống. Chúng minh họa đường đi của dữ liệu và cấu trúc lưu trữ, không chỉ là sơ đồ khái niệm.




Hình 1. Quy trình kiểm tra tự động: các bước chất lượng, giao diện và dựng Docker hoàn tất với trạng thái thành công trong cùng một lần chạy.



Hình 2. Cấu trúc PostgreSQL/pgvector: bảng document_chunks có content dạng text, metadata dạng jsonb, embedding vector(2048), khóa liên kết document_id và chỉ mục theo tài liệu.



Hình 3. Giao diện kho tài liệu sau khi tải lên: sáu tài liệu đã xuất hiện, tài liệu Shopee được chọn, bản xem trước PDF và phần văn bản đã định dạng được hiển thị cùng số lượng chunk.



Hình 4. Màn hình xem chunk: nội dung được chia thành các đoạn có thứ tự, giữ tiêu đề, trang và văn bản liên quan để bước truy xuất có thể chọn đúng phần.

5. Nghiên cứu và xử lý dữ liệu

5.1 Hồ sơ dữ liệu

Benchmark gồm 877 câu hỏi trên 5 PDF. Bảng chiếm 299 câu, biểu mẫu 107, hình 159, chú thích/đánh dấu 285 và văn bản thường 27. Việc phân loại giúp không dùng một chiến lược chunk/OCR cho mọi loại nội dung.

Loại dữ liệu	Số câu	Rủi ro cần kiểm soát
Bảng	299	Mất quan hệ hàng, cột và tiêu đề
Biểu mẫu	107	Nhãn và giá trị bị tách rời
Hình	159	Dữ kiện nằm trong sơ đồ/hình
Chú thích	285	Callout, tô màu, vùng đánh dấu
Văn bản	27	Header/footer và chunk quá ngắn

5.2 Thiết kế phép đo

- Document hit: tài liệu đúng xuất hiện trong kết quả.
- Content hit: kết quả có đoạn chứa dữ kiện trả lời.
- Assertion pass: câu trả lời đúng mệnh đề được kiểm tra.

Ba chỉ số được đọc cùng nhau. Document hit cao nhưng content hit thấp nghĩa là hệ thống biết tên tài liệu nhưng chưa tìm được bằng chứng; content hit có nhưng assertion pass thấp chỉ ra vấn đề ở bước tổng hợp hoặc diễn đạt.

5.3 So sánh phương án

Phương án	Kết quả	Quyết định
Ban đầu	85,52% document; 33,52% content; 18,59% pass	Mốc
OCR toàn trang	34,44% content; 19,73% pass	Giữ
OCR + ứng viên x8	88,26% document; 37,66% content	Giữ
Hybrid dense + lexical	90,65% document; 41,33% content; 23,72% pass	Baseline
Structured table toàn cục	Content còn 36,85%	Loại
Visual element + region OCR	Figure 34/159 hit; 19/159 pass	Giữ cho hình
OCR tile cố định	Annotation 92/285 hit, thấp hơn tuyến ngữ cảnh	Loại

5.4 Quyết định kỹ thuật từ dữ liệu

- Tài liệu quét: OCR toàn trang NVIDIA có timeout và fallback để không treo job.
- Bảng: giữ quan hệ tiêu đề-hàng-cột, thêm chunk cha và điều hướng theo câu hỏi.
- Hình: lưu crop, page, bbox và metadata; benchmark cho thấy chỉ mục phần tử riêng tốt hơn gắn ảnh vào chunk trang.
- Chú thích: không mặc định dùng OCR lát cắt cố định; cần detector theo hình học và quan hệ vùng đánh dấu.
- Truy xuất: kết hợp dense và lexical, mở rộng tập ứng viên rồi mới rerank theo khả năng trả lời.

6. Kiểm thử đơn vị và kiểm thử API

Lệnh kiểm tra chính là `ruff check app tests, python -m compileall -q app tests` và `python -m pytest -q tests`. Kết quả gần nhất: 22 kiểm thử đạt; kiểm thử gọi dịch vụ NVIDIA trực tiếp được bỏ qua khi môi trường không có khóa API, còn các kiểm thử ngoại tuyến vẫn chạy bình thường.

6.1 Kiểm thử thành phần lỗi

Mục tiêu: bảo đảm dữ liệu đầu vào được làm sạch và chia đúng trước khi tạo vector. Mẫu kiểm tra: chuỗi có khoảng trắng thừa, ba dòng xuống dòng liên tiếp và một ký tự điều khiển phải trở thành một dòng trống đúng chuẩn; đoạn văn có số trang và tiêu đề phải giữ lại trang/phần; hộp giới hạn phải được chuẩn hóa về cùng hệ tọa độ. Nếu một ký tự điều khiển làm thay đổi nội dung hoặc mất số trang, kiểm thử thất bại.

6.2 Kiểm thử hợp đồng API

Mục tiêu: xác nhận dịch vụ phản hồi đúng khi người dùng gọi API. Mẫu kiểm tra trạng thái hoạt động: gửi `GET /health` và yêu cầu mã phản hồi thành công cùng trạng thái dịch vụ cơ sở dữ liệu. Mẫu hỏi đáp: gửi `POST /query` với câu hỏi hợp lệ và kiểm tra có câu trả lời cùng nguồn. Mẫu lỗi: câu hỏi rỗng phải trả lỗi 400; tệp ngoài PDF/TXT/DOCX phải bị từ chối; tệp hợp lệ phải trả trạng thái `queued` và mã tài liệu; truy vấn không có bằng chứng phải trả `sources` rỗng, không dựng nguồn giả.

6.3 Kiểm thử xếp hạng bằng chứng

Mục tiêu: đoạn chứa dữ kiện quyết định phải đứng trên đoạn chỉ trùng chủ đề. Mẫu kiểm tra: với câu hỏi về thời gian hoàn tiền thẻ NAPAS, đoạn có “2-5 ngày làm việc” phải vượt đoạn chỉ nói thời hạn trả hàng; đổi tên tệp nhưng giữ nguyên nội dung không được làm thay đổi điểm nội dung. Kiểm thử cũng xác nhận đoạn Kamereo, Microsoft hoặc chính sách bảo hành khác không lọt vào khi câu hỏi chỉ hỏi Shopee.

6.4 Kiểm thử nhận dạng ký tự và định tuyến

Mục tiêu: chọn đúng cách đọc theo loại tài liệu. Mẫu kiểm tra: PDF đã có lớp chữ phải đi đường tắt, PDF quét phải chuyển sang OCR NVIDIA, dấu tiếng Việt phải được sửa khi OCR trả ký tự lỗi, vùng bảng phải giữ hộp giới hạn và hệ thống phải dừng đúng thời gian khi mô hình OCR chậm. Văn bản sau OCR phải được đánh dấu phương pháp trích xuất và độ tin cậy để có thể kiểm tra lại.

6.5 Kiểm thử kết nối mô hình NVIDIA

Mục tiêu: kiểm tra cấu hình, chia lô và khả năng thử lại mà không bắt buộc gọi dịch vụ trực tuyến trong mọi lần chạy. Mẫu kiểm tra: đọc đúng mô hình, chia trang thành các lô có kích thước giới hạn, giữ thứ tự trang sau khi xử lý song song, và từ chối câu trả lời không có bằng chứng. Khi thiếu khóa truy cập, phần gọi trực tuyến được bỏ qua có chủ đích; các kiểm thử ngoại tuyến vẫn phải đạt.

6.6 Kiểm chứng truy xuất

Mục tiêu: kiểm tra độc lập việc tạo vector và tìm đúng đoạn. Mẫu kiểm tra gồm các câu hỏi về thời hạn hoàn tiền, phí trả hàng, chính sách bảo hành, hotline và xử lý hàng lỗi; mỗi câu lưu lại tài liệu mong đợi, tài liệu nhận được, câu trả lời mong đợi và câu trả lời thực tế để đánh giá ở mục 8.

Kiểm thử API dùng dịch vụ giả lập để kiểm tra hợp đồng phản hồi: câu trả lời phải đi kèm sources; câu hỏi rỗng phải bị từ chối; truy vấn không có bằng chứng không được sinh nguồn giả; file không hỗ trợ phải trả lỗi; upload hợp lệ phải trả trạng thái queued.

7. Cấu hình và nguồn sự thật

Cấu hình được tách khỏi mã nghiệp vụ. Tệp cấu hình mẫu chỉ chứa giá trị mẫu; giá trị thật được nạp từ môi trường và không đưa vào mã nguồn. Bộ đọc cấu hình kiểm tra kiểu dữ liệu và cung cấp giá trị mặc định cho máy phát triển.

Nhóm	Biến cấu hình	Tác dụng
Kết nối	DATABASE_URL, POSTGRES_DB, POSTGRES_USER	Kết nối PostgreSQL/pgvector và tên cơ sở dữ liệu
Mô hình	EMBEDDING_MODEL, EMBEDDING_DIM, LLM_MODEL	Mô hình tạo vector, số chiều và mô hình sinh
Chia đoạn	CHUNK_SIZE, CHUNK_OVERLAP	Kích thước đoạn và phần chồng lấn
Truy xuất	TOP_K, RETRIEVAL_CANDIDATE_MULTIPLIER, SIMILARITY_THRESHOLD	Số bằng chứng, tập ứng viên và ngưỡng lọc
OCR	NVIDIA_OCR_MODEL, NVIDIA_OCR_TIMEOUT_SECONDS, NVIDIA_OCR_BATCH_SIZE	Mô hình, thời gian chờ và kích thước lô OCR
Chuẩn hóa	NIM_MODEL, NIM_REQUEST_TIMEOUT_SECONDS, NIM_MAX_RETRIES	Mô hình ngữ nghĩa, thời gian chờ và số lần thử lại

Khi triển khai, chỉ cần thay các biến môi trường và khởi động lại dịch vụ. Luồng xử lý không cần sửa mã nguồn để đổi mô hình, kích thước đoạn, số lượng kết quả hay thời gian chờ.

8. Đánh giá từng trường hợp kiểm tra truy xuất

Bảng kiểm tra truy xuất có 8 câu hỏi có dữ liệu; hai dòng cuối để trống nên không được tính là trường hợp kiểm tra. Cách đánh giá: Đạt khi câu trả lời chứa đủ ý chính và không mâu thuẫn; Đạt một phần khi có ý chính nhưng thiếu điều kiện hoặc thêm thông tin chưa có căn cứ; Chưa đạt khi mâu thuẫn với đáp án hoặc bỏ sót dữ kiện quyết định.

1. Hoàn tiền bằng thẻ NAPAS

Câu hỏi: shopee trả hàng thẻ napas mấy ngày tiền về ví vậy

Đáp án chuẩn: Sau khi Shopee xác nhận hoàn tiền, tiền về thẻ hoặc tài khoản liên kết trong 2-5 ngày làm việc; thứ bảy, chủ nhật và ngày lễ không tính.

Kết quả hệ thống: Hệ thống trả đúng thời gian 2-5 ngày làm việc, đúng phương thức hoàn về thẻ NAPAS và phù hợp với dữ kiện cần trả lời.

Đánh giá: Đạt

2. Shop giao sai hàng và phí trả hàng

Câu hỏi: Shop giao sai đồ, chọn bưu tá hay bưu cục có mất phí không và điều kiện được hỗ trợ cước là gì?

Đáp án chuẩn: Lấy hàng tại nhà và gửi tại bưu cục được miễn phí; tự sắp xếp thì trả trước rồi được hỗ trợ khi đủ điều kiện. Cần yêu cầu được chấp nhận, mã vận đơn hợp lệ và thông tin trả hàng đầy đủ.

Kết quả hệ thống: Hệ thống đã phân biệt ba cách gửi, nêu điều kiện chấp nhận, mã vận đơn và thời hạn yêu cầu.

Đánh giá: Đạt

3. Đổi riêng áo lỗi trong một bộ

Câu hỏi: Mua bộ áo quần, áo lỗi sau 5 ngày; có đổi hoặc hoàn riêng áo không?

Đáp án chuẩn: Được báo lỗi trong 7 ngày, nhưng chính sách chưa nói rõ có tách riêng áo khỏi bộ hay phải gửi cả bộ.

Kết quả hệ thống: Hệ thống khẳng định được gửi riêng áo và hoàn tiền toàn bộ, vượt quá bằng chứng.

Đánh giá: Chưa đạt

4. Phụ kiện Adore

Câu hỏi: Phụ kiện không được bảo hành trọn đời thì lỗi do nhà sản xuất trong 7 ngày có được đổi không?

Đáp án chuẩn: Phụ kiện không thuộc bảo hành trọn đời; chính sách cung cấp chưa đủ để kết luận chắc chắn nhánh đổi hàng lỗi có áp dụng cho phụ kiện.

Kết quả hệ thống: Hệ thống khẳng định chắc chắn được đổi trong 7 ngày, đồng thời trộn điều kiện bảo hành với đổi hàng.

Đánh giá: Chưa đạt

5. Bảo hành biến tần GD100-PV

Câu hỏi: Biến tần bơm năng lượng mặt trời GD100-PV được bảo hành bao lâu và tính từ ngày nào?

Đáp án chuẩn: Thời hạn 1,5 năm, tính từ ngày giao hàng ghi trên hóa đơn hoặc phiếu giao hàng.

Kết quả hệ thống: Hệ thống trả đúng thời hạn 1,5 năm và đúng mốc bắt đầu từ ngày giao hàng.

Đánh giá: Đạt

6. Inverter gửi tới Nguyễn Văn Quá

Câu hỏi: Gửi inverter hòa lưới tới trạm Nguyễn Văn Quá mất bao lâu, ai chịu cước và máy nút vỡ xử lý thế nào?

Đáp án chuẩn: Hoàn tất sửa chữa trong 24 giờ làm việc từ lúc nhận thiết bị; khách chịu cước gửi đến trung tâm; nếu không đủ điều kiện bảo hành thì báo giá, khách đồng ý mới sửa và chịu cước gửi về; nếu đủ điều kiện thì trung tâm chịu cước gửi trả.

Kết quả hệ thống: Hệ thống thiếu mốc 24 giờ, thiếu quy trình báo giá khi nút vỡ và chỉ trả một phần cước.

Đánh giá: Chưa đạt

7. Hotline Kamereo

Câu hỏi: Cho xin số hotline khiếu nại và đổi hàng Kamereo.

Đáp án chuẩn: Hotline 0812 46 37 27.

Kết quả hệ thống: Hệ thống trả đúng số hotline theo tài liệu.

Đánh giá: Đạt

8. Rau củ dập úng sau 14 giờ

Câu hỏi: Nhận rau lúc 15 giờ 30, hàng dập úng; có được trừ ngay công nợ hay phải xử lý thế nào?

Đáp án chuẩn: Không trừ ngay công nợ; sau 14 giờ chỉ đổi hoặc bù ở đơn kế tiếp sau khi gửi thông tin và hình ảnh để xác minh.

Kết quả hệ thống: Hệ thống trả đúng nguyên tắc không trừ tiền ngay, đổi/bù ở đơn kế tiếp và yêu cầu cung cấp bằng chứng.

Đánh giá: Đạt

Kết quả tổng hợp: 5/8 câu đạt đầy đủ và 3/8 câu chưa đạt. Các lỗi chính là bỏ sót đoạn chứa dữ kiện quyết định, trộn hai chính sách khác nhau và suy diễn khi tài liệu chưa đủ căn cứ.

9. Cách tạo source trong câu trả lời

Source không do mô hình sinh tự đặt ra. Dịch vụ hỏi đáp lấy source từ những chunk đã vượt qua truy xuất kết hợp, lọc danh tính tài liệu, phân bố điểm và xếp hạng bằng chứng. Với mỗi chunk được chọn, hệ thống tạo một khối bằng chứng có tên file, mã chunk và trang trước khi gọi mô hình.

Trường trong source	Ý nghĩa
file_name, document_id	Tài liệu và bản ghi tài liệu gốc
chunk_id, page, page_start, page_end	Đoạn và vị trí có thể mở lại để kiểm tra
dense_score, bm25_score, similarity_score	Điểm vector, điểm từ khóa và điểm tương đồng
query_compatibility_score, answerability_score	Mức phù hợp với câu hỏi và khả năng chứa dữ kiện trả lời
source_locator, element_ids, section	Vị trí, phần tử bố cục và mục nội dung
extraction_method, ocr_confidence, snippet	Cách lấy dữ liệu, độ tin cậy OCR và đoạn xem nhanh

Trong prompt, bằng chứng được đánh dấu dạng [EVIDENCE #... | File... | Chunk... | Trang...]. Sau khi mô hình sinh câu trả lời, API trả lại answer cùng mảng sources; nếu không có bằng chứng thì sources rỗng và hệ thống không dựng nguồn giả.

10. Hạn chế và kế hoạch tiếp theo

- Bộ đánh giá hiện tập trung 5 PDF SynthDocQA; cần thêm bộ tài liệu thực tế cân bằng theo loại dữ liệu.
- Chỉ mục phần tử hình và OCR vùng chú thích chưa bật cho mọi tài liệu vận hành.
- Bộ xếp hạng hiện dựa trên luật; chưa có mô hình xếp hạng học từ phản hồi người dùng.
- Cần nạp lại tài liệu, chạy đánh giá hồi quy và theo dõi độ trễ, tỷ lệ OCR dự phòng, tỷ lệ không có bằng chứng theo loại dữ liệu.

Chi tiết phương pháp, phân tích lỗi, bảng kết quả đầy đủ và quy trình tái lập nằm trong hồ sơ nghiên cứu dữ liệu. File PDF này là bản trình bày có dẫn chứng; hồ sơ nghiên cứu là nơi lưu giải thích đầy đủ.